

Relatório 3 - O que é Inteligência Artificial e Aprendizado de Máquina? (I)

Yuri Vacelh Zamulhak Zdebski

Descrição da atividade

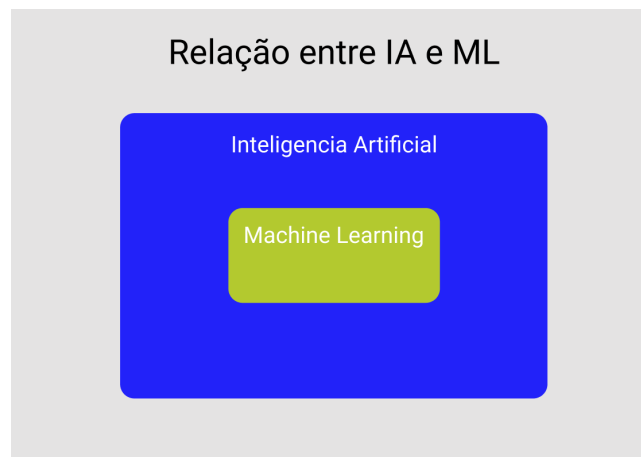
A atividade propôs a leitura de 2 artigos que falam sobre inteligência artificial (IA) e machine learning (ML).

Inteligência artificial (IA) x machine learning (ML)

IA e ML são frequentemente confundidos devido às suas semelhanças. Este artigo esclarece esses conceitos, explicando suas conexões, diferenças e benefícios, além de citar aplicações em diversas áreas do conhecimento.

Partindo da definição dada pelo artigo, temos que IA é um campo que visa, por meio de tecnologias, simular funções cognitivas humanas (como por exemplo ver, ler, conversar), IA pode ser dividida em ANI, AGI e ASI. ML nada mais é do que com base em dados já coletados, ensinar uma máquina a realizar uma tarefa específica (como por exemplo identificar imagens), ou seja ML é um subconjunto do grande campo de estudos de IA.

Figura 1: Diagrama representando a relação IA/ML



Fonte: Autoria própria.

Tendo isso em mente, algumas das principais diferenças são:

- IA visa simular inteligência humana, ML ensinar uma máquina a realizar determinada tarefa
- IA pode utilizar dados estruturados, semiestruturados e não estruturados, ML apenas estruturados e semiestruturados
- IA utilizam de técnicas como lógica e árvores de decisão, ML depende de modelos estatísticos e grandes quantidades de dados

Portanto podemos chegar a IA sem ML, mas não o contrário, ML é apenas um dos possíveis (e mais promissores) caminhos.

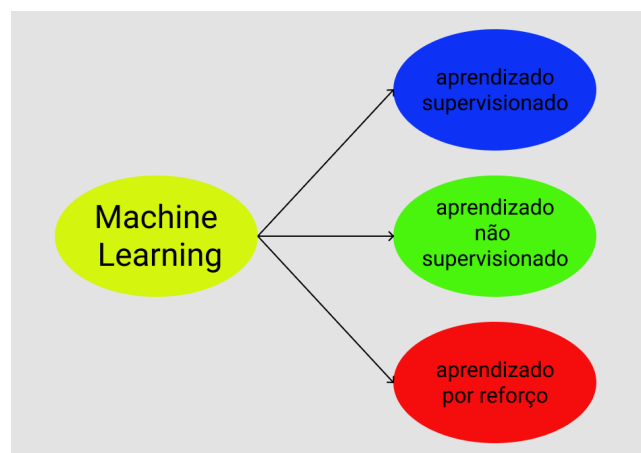
Inteligência Artificial e Aprendizado de Máquina - Relação, conceitos, desafios e áreas de Integração

O segundo artigo, postado por Arsénio António Monjane no LinkedIn trata de ML de forma mais específica. A definição dada pelo autor é que, é uma técnica de IA em que a máquina não aprende a realizar a tarefa por programação explícita, mas sim por identificar padrões em grandes quantidades de dados. Nesse contexto alguns dos jargões utilizados são:

- Conjunto de dados/Dataset: As informações em que o modelo utiliza para aprender, são organizados em um conjunto tabelado de entradas e saídas (resposta esperada do sistema), alguns exemplos práticos são imagens de caracteres escritos a mão, dados de especulação econômica e transcrições de fala para texto
- Aprendizado: Processo em que o algoritmo tenta encontrar padrões no conjunto de dados, na esperança de que, para entradas reais, a saída seja próxima da esperada.
- Modelo: É o conhecimento adquirido pelo algoritmo de aprendizado, ele que realiza as previsões ou classificações para novos dados.
- Treinamento: É o processo prático que "realiza" o aprendizado, modificando o modelo iterativamente para que se ajuste ao problema proposto.
- Teste: Como o nome indica, fase em que o modelo é testado, avaliando dados que não foram vistos durante o treinamento. O "pente fino" para dizer se o modelo precisa de ajustes ou não

Cada problema envolvendo ML tem suas peculiaridades, principalmente na forma que o dataset está disposto. Sabendo disso, existem 3 possíveis aproximações para treinar o modelo, sendo elas o aprendizado supervisionado, o não supervisionado e o por reforço.

Figura 2: Diagrama representando a relação IA/ML



Fonte: Autoria própria.

Começando pela forma (que eu acredito ser) mais intuitiva, o aprendizado supervisionado. Para esse caso, o conjunto de dados deve estar organizado de tal forma que existam entradas e uma saída correspondente, tida como correta. Então, durante o período de treino, o algoritmo de aprendizado pode se autorregular com base na saída que era esperada, porém isso da brecha

para erro humano, resultando em um aprendizado equivocado. Algumas possíveis aplicações dessa abordagem são, reconhecimento de imagens e objetos, detecção de spam e previsão de preços de imóveis. Alguns algoritmos comumente utilizados são, redes neurais, regressão linear e máquinas de vetor de suporte (SVM).

A contrapartida do aprendizado supervisionado é o não supervisionado, em que o conjunto de dados não tem nenhuma saída esperada, deixando para que o algoritmo encontre os padrões e agrupar os dados por conta própria. As abordagens mais utilizadas são o clustering, regras de associação e regras de dimensionalidade. O clustering é uma técnica de mineração de dados que agrupa os dados não rotulados. Os algoritmos de armazenamento em cluster podem ser categorizados em alguns tipos, especificamente exclusivos, sobrepostos, hierárquicos e probabilísticos. As regras de associação, como o nome indica, se baseiam em regras para encontrar relacionamentos entre variáveis. Existem diversos algoritmos para esse fim, porém o Apiori é o mais amplamente utilizado.

Por ultimo, temos o aprendizado por reforço, esse tipo de aprendizado não é somente utilizado para treinar máquinas, podendo ser aplicado a praticamente qualquer coisa ser vivo que reconheça padrões. Consiste em recompensar comportamentos positivos e "punir" comportamentos negativos (o punir entre aspas pois a punição pode ser simplesmente a ausência da recompensa, o que não necessariamente configura uma punição), sendo a recompensa um *feedback* composto de um valor numérico, em que a máquina tenta maximizar. Alguns dos algoritmos utilizados são Q-learning, métodos de gradiente de políticas e métodos de Monte Carlo. Uma das possíveis aplicações é o treinamento de um modelo para jogar xadrez, visto que, cada jogada pode ser quantizada, sendo esse o parâmetro utilizado para "refinar" as jogadas.

Conclusões

Machine Learning é uma das áreas da ciência da computação em maior ascensão nos últimos anos, principalmente com a popularização das LLM's, sem dúvidas tendo aplicações em diversas áreas do conhecimento (desde medicina até linguística). Porém, ainda existem grandes desafios a serem superados, como questões energéticas, éticas (aquisição de dados, por exemplo) e problemas gerados pelos próprios métodos de treinamento (como underfitting e overfitting). Além disso, para que possamos aproveitar ao máximo dos benefícios claros que essas tecnologias trazem para a sociedade como um todo, há a necessidade de tornar os modelos mais interpretáveis e transparentes, para que suas decisões possam ser compreendidas e justificadas.

Referências

<https://www.linkedin.com/pulse/inteligência-artificial-e-aprendizado-de-máquina-relação-monjane/>
<https://cloud.google.com/learn/artificial-intelligence-vs-machine-learning?hl=pt-br>
<https://www.ibm.com/think/topics/ai-vs-machine-learning-vs-deep-learning-vs-neural-networks>
<https://www.ibm.com/br-pt/topics/supervised-learning>
<https://www.ibm.com/br-pt/topics/unsupervised-learning>
<https://aws.amazon.com/pt/what-is/reinforcement-learning/>